重庆大学
CHONGQING UNIVERSITY

基于STM32的轻量化目标检测小车

算力受限下的「可信感知」

置信度分级 · 定向复核 · 帧间补位

答辩人：陶家宇，王紫怡，李海洋，徐熠冉

指导老师：刘 寄

目录

CONTENTS

1 选题依据 WHY THIS TOPIC

2 创新点 WHAT IS NEW

3 技术路线 HOW WE BUILD

4 预期成果 WHAT WE GET

5 团队分工 WHO DOES WHAT

6 参考文献 REFERENCES

重庆大学
CHONGQING UNIVERSITY

01 选题依据

从「能不能在 MCU 上跑检测」，
到「跑不准的时候怎么办」

耐劳苦，尚俭朴，
勤学业，爱国家。

一帧的代价

THE COST OF ONE FRAME · 105 / 240 / 359 ms —— 差多少不重要，都太慢

重庆大学 CHONGQING UNIVERSITY

厂商实测

105.8 ms

STM32H735 @550 MHz
SSD-MobileNetV1-0.25
192×192，INT8，纯推理

开源复现

240 ms

STM32H743 + OV5640
mAP 31.8%，约 4–5 FPS
推理本体约 235 ms

论文实测

359 ms

STM32H7A3 @192 MHz
TinyissimoYOLO 最小检测网
IEEE Access 2024

0.3 m/s × 240 ms = 7.2 cm

车以 0.3 m/s 行进时，一帧检测的 240 ms 里车身已前移 7.2 cm
——比一个物料盒（约 5 cm）还宽。

所以真正的问题不是「MCU 能不能跑目标检测」——能，三个来源都证明了。

问题是：在 4 FPS 的感知下，一台会动的车怎么才不出事。

耐劳苦 尚俭朴 勤学业 爱国家

已有工作的三条边界

THREE BOUNDARIES · 我们该在哪里做贡献

重庆大学 CHONGQING UNIVERSITY

01	工具链：已经不缺	Cube.AI、TFLite Micro、CMSIS-NN、DORY、MicroNets —— 从训练到部署的自动链路是齐的。CMSIS-NN 相比朴素实现吞吐 4.6×、能效 4.9×。	**部署本身不再是问题，我们不在这条线上做贡献。**
02	模型：已经压到极限	TinyissimoYOLO 把检测网压到百万参数以内；NanoDet-Plus 的 int8 版本 980 KB，已经贴着 1 MB Flash 走。	**9 个月、大一团队去改网络结构，投入产出比不成立。**
03	可靠性：才刚起步	「模型知道自己不确定」云端已成熟（2017 起）。MCU 上已有 QUTE、TCUQ（2025）、TrustTiny-HAR（2026）三代，但都停在「给分数、做拒识」。2026 年出现了「弃权后去取证」——Co-GLANCE 派另一台机器人，BCEA 让模型回看图像。	**前沿已走到「取证」，但不在这一档芯片上。**

缺的不在前两条。分数有了、该去取证也有了，缺的是最后一公里：车该做什么？

耐劳苦 尚俭朴 勤学业 爱国家

重庆大学
CHONGQING UNIVERSITY

02

创新点

三个点，都落在「感知不可靠」这一侧

不改网络结构，不加第二块芯片

耐劳苦，尚俭朴，
勤学业，爱国家。

三个创新点

THREE IDEAS · 一条系统主张，三个可验收的环节

重庆大学 CHONGQING UNIVERSITY

①

让模型说出
这一帧靠不靠得住

帧级错误指示器

把推理过程本来就会产生的几个量凑成一个判据，输出可用 / 存疑 / 弃用三档。
不训练新模型，不加分支。

②

什么时候去问超声波
由模型决定

触发式定向复核

不是每帧加权融合，只在不确信时唤醒超声、对准检测框方位复核。
把融合的「权重」换成融合的「时机」。

③

4 fps 的感知
驱动 100 Hz 的控制

帧间运动学补位

两帧之间用陀螺和编码器把旧框推演过来（跟踪器的 predict 环节），
让控制环看到连续目标，而不是跳变的框。

三条都在系统层。方法全部借自前人（选择性预测、conformal 校准、惯性推演），我们的活是：在「没有推理加速器的那一档 M7」上，把它们拼成一条能跑通的链，并给出时延与能量的实测账。

耐劳苦 尚俭朴 勤学业 爱国家

帧级可信度判定

IDEA 01 · FRAME-LEVEL CONFIDENCE

重庆大学 CHONGQING UNIVERSITY

核心一句话：让模型自己说，这一帧靠不靠得住。

四个几乎不要钱的信号

S1

top1 − top2 间隔

INT8 域直接相减，不反量化、不跑 exp

S2

量化饱和率

被 clamp 到 ±127 的激活占比——量化模型独有的失效信号

S3

帧间一致性

相邻帧框的 IoU，与 IMU 预测位移的残差

S4

输出熵（对照组）

LUT + 整数移位做定点近似，用来判断有没有必要

输出：三档判定 + 一个时间戳

W **可用**
决策层正常使用

U **存疑**
降速，交给下一环复核

R **弃用**
不参与决策，转反应式

这些量都来自推理过程本身：不新增网络分支，不新增第二个模型，内存增量在个位数 KB。

要证的指标（目标值） 错误帧召回 ≥ 70% • 存疑档触发率 ≤ 30% • 定点版相对浮点版判别力损失 ≤ 5 个点

阈值不写死：验证集分位点定 W / U 分界，并报告它换光照、换校准集的漂移量。四信号若都没判别力，就如实写「走不通」。

耐劳苦 尚俭朴 勤学业 爱国家

什么时候去问超声波

IDEA 02 · WHEN TO FUSE, NOT HOW TO WEIGH

核心一句话：融合的不是权重，是时机。

两种融合理念

通行做法：每帧加权融合

超声与视觉按固定权重平均，或按场景切换权重。代价恒定：视觉判断错的时候，超声的正确读数会被平均值一起带偏。

我们的做法：把「权重」换成「时机」

超声平时休眠。只有模型报「存疑」时才唤醒它，对准检测框方位测三次，把它当第二个证人，而不是参与平均的一个分量。

三档对应的三个动作

W　正常速度前行

超声休眠，只有视觉在工作

U　降速 50%，定向复核

框方位 ±30° 内测距 3 次，两证人一致才通过

R　停车 / 反应式避障

视觉退出决策，超声波主导，慢速试探

必须同时成立的三件事

① 触发不能太频繁也不能太慢：存疑档占比 ≤ 30%，触发到出复核结果 ≤ 150 ms

② 不能拿安全换时间：W 档的漏检率不得高于全帧融合　③ 真能降错：视觉误检场景下，误动作率相对单视觉基线下降 ≥ 50%

复核只投否决票、不重算分数——重算会让错误率超目标 13 个百分点（BCEA 2026）。指标因此换掉：不比 mAP，比误动作率、漏检代价、时延。

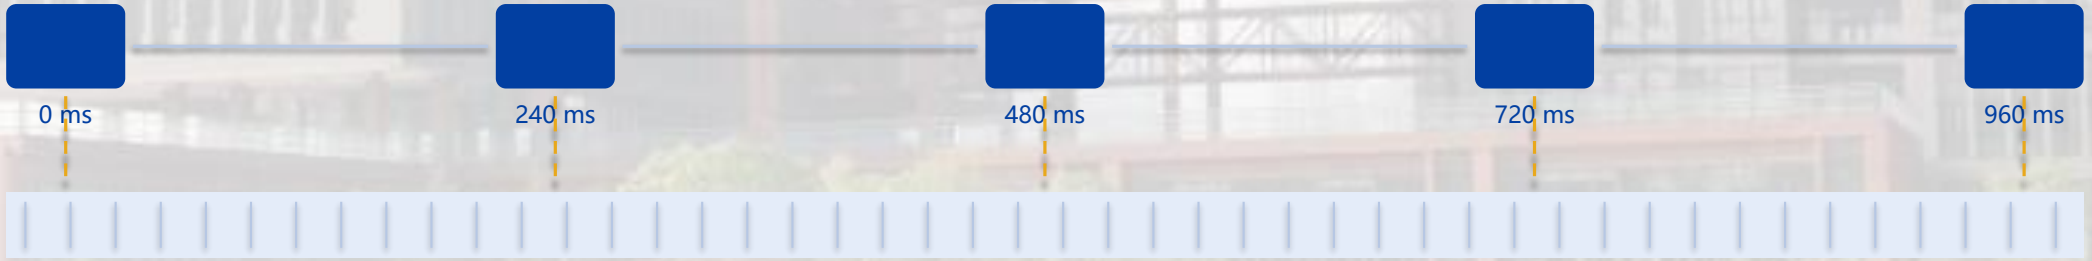
耐劳苦 尚俭朴 勤学业 爱国家

两帧之间怎么补上

IDEA 03 · BETWEEN THE FRAMES

核心一句话：4 fps 的感知，要让 100 Hz 的控制觉得自己一直在看。

检测帧 4 fps（每 240 ms 一帧）



控制环 100 Hz：每 240 ms 更新 24 次，只有 1 次拿到新检测

其余 23 次，位置靠陀螺 + 编码器推演

为什么非补不可

把 240 ms 前的旧框直接喂给 PID，等于给控制环加了固定相位滞后——车会画龙、过冲、在障碍前反复修正。这是控制里的常识，但在五十块钱的四轮小车上没人认真处理。

怎么证明它有用

同一段避障路线跑 20 次，只切换「补位开 / 关」一个变量，比两个数：轨迹最大横向偏差、电机指令差分的 RMS。两条曲线应该能明显分开。

平面 3-DoF 推演：$p(t) = p(t_0) + R(\Delta\theta)\cdot v\cdot\Delta t$　　不确定度随时间增长：$\sigma(t) = \sigma_0 + k\cdot\Delta t$（不做卡尔曼，只做显式线性增长，好解释也好调）

定位说明：这一条是工程创新，不是方法创新——高频惯性 + 低频视觉是成熟常识。
我们的价值在于把它在定点运算、几十 KB RAM、没有浮点余量的条件下做到能用，并把收益量化出来。

耐劳苦 尚俭朴 勤学业 爱国家

我们站的位置

WHERE WE STAND · 五列里最关键的是最后两列

代表工作	平台	任务	感知自身可靠性	拿它做什么
TFLite Micro / CMSIS-NN / MLPerf Tiny	Cortex-M 等	分类、唤醒词、基准	不做	—
DORY / MicroNets / TinyissimoYOLO	MCU / GAP9	分类、检测部署	不做	—
Deploy-SSD-ON-STM32	STM32H743	目标检测	不做	—
QUTE / TCUQ（2025）	STM32L4	分类、音频	做：方差 / 时序一致性	拒识（预算化）
TrustTiny-HAR（2026）	STM32L4	人体动作	做：校准 + OOD	拒识 / 上云
Thinking Fast（2026）	GAP9	深度估计	做：置信度门控	唤醒更贵的传感器
Co-GLANCE / BCEA（2026）	GPU / 云端	遮挡、LVLM 幻觉	做：conformal 两级	派另一台机器人去看
本项目	**STM32H743**	**目标检测**	**做：三档判定**	**触发定向复核 + 降级控制**

前四行证明「能跑」；中间四行证明「知道自己不可靠」，但停在分类/音频/人体动作，或者必须靠 GPU、GAP9 才跑得动。QMA 也用饱和率，但查模型退化、不判单帧。

我们落在的格子：目标检测（实例级框）× 没有推理加速器的 M7 × 本地传感器复核 × 硬实时 ≤150 ms × 有能量账。

耐劳苦 尚俭朴 勤学业 爱国家

重庆大学
CHONGQING UNIVERSITY

03 技术路线

六个里程碑，每一级都有验收标准
卡不住的不硬上，卡住了就降级

耐劳苦，尚俭朴，
勤学业，爱国家。

六个里程碑，每级有验收

ROADMAP · 每一级不通过就不往下走

重庆大学 CHONGQING UNIVERSITY

2026.11.30	2027.02.19	2027.04.14	2027.06.16	2027.07.15	2027.08.15
选型与跑通	**量化预演**	**端侧推理**	**融合联调**	**系统优化**	**结题**
相机出图、Cube.AI 跑通一个官方模型、内存账算平	PC 端 INT8 量化，跑通后处理，标定精度损失	模型上板，静态内存划分，测首次端到端帧率	三档判定与触发式复核接入，实车跑通识别与避障	帧间补位上线，数据补齐，写部署流程文档	整理源码、报告、数据表，投稿或提交专利申请
官方模型能在板上跑起来	**精度损失 < 3 个点**	**≥ 3 fps，内存不溢出**	**中期检查可演示**	**清单里的指标全部测满**	**结题材料齐全**

卡点怎么处理（现在就写清楚，免得到时候硬撑）

2027.04.14 端侧跑不通 → 立刻砍掉创新点③，把资源压到①②，保住「能识别 + 能避障」这条底线；
2027.02.19 量化精度崩了 → 优先降输入分辨率（192→160）和减类别（3 类以内），不改网络结构。

耐劳苦 尚俭朴 勤学业 爱国家

为什么不买开发板而是核心板

HARDWARE · 选型的第一个约束是内存，不是主频

器件	型号与关键参数	预算	为什么是它
感知主控	STM32H743VIT6 核心板 2 MB Flash / 1 MB RAM / 480 MHz	130 元	192×192 检测模型要 330 KB Flash、174 KB 激活 RAM
摄像头	OV2640，DCMI 接口，200 万像素	30 元	支持 JPEG 输出，省 MCU 端编码开销
超声波 ×2	HC-SR04，2–400 cm，波束约 15°	10 元	波束窄，才能做「定向复核」
姿态	MPU6050，6 轴，I²C	8 元	帧间推演只需要陀螺，不需要磁力计
底盘	F103C8T6 + DRV8833 + 60 mm 麦轮（已有）	0 元	已随机器人竞赛搭好并验证过

为什么不是 H750

H750 只有 128 KB 内部 Flash，而 192×192 检测模型的权重就 277 KB，必须外挂 QSPI 并改启动链路。多花的钱不多，多踩的坑不少。

资源账（ST model zoo 实测口径）

192×192 INT8 检测模型：激活 RAM 166 KB + 运行时 8 KB = 174 KB；权重 277 KB + 代码 53 KB = 330 KB Flash。放在 1 MB / 2 MB 里，Flash 和 RAM 都用了不到两成，余下的够开双缓冲和日志。

合计约 178 元（核心板方案），在 450 元额度内；量产换 H723 裸片打板，BOM 降到 86 元。

耐劳苦 尚俭朴 勤学业 爱国家

四个会疼的地方

RISKS · 先想好怎么退，才敢往前走

风险	什么时候能看出来	怎么办
量化后精度崩掉 mAP 掉一半以上	2027.02 量化预演阶段 PC 端就能看到逐层误差	先降输入分辨率（192→160），再减类别（≤3 类）； 仍不行就上量化感知训练，但那是备选不是首选
端侧帧率达不到 3 fps	2027.04 端侧推理阶段 首次跑通就能测	只对图像下半区 / ROI 推理； 或换成单阶段、无 NMS 的更小模型
四个置信度信号都没判别力	2027.05 三档模块单独测 画风险—覆盖率曲线	退回以帧间一致性为主； 创新点①降级为工程手段，答辩与论文里如实写
九个月做不完	每级里程碑的验收标准 不给过就不往下走	04.14 卡住就砍创新点③； 06.16 卡住就把「定向复核」降为「定时复核」

这几条不是走过场。尤其第三条——如果测出来这套判据没用，我们会把结论照实写进结题报告，而不是换一套说法圆回去。

耐劳苦 尚俭朴 勤学业 爱国家

重庆大学
CHONGQING UNIVERSITY

04 预期成果

能拿出手的四样东西
以及两件现在就该说清楚的事

耐劳苦，尚俭朴，
勤学业，爱国家。

四样能拿出手的东西

DELIVERABLES · 以及两件现在就该说清楚的事

重庆大学 CHONGQING UNIVERSITY

实物

一台能演示的车

现有底盘 + H743 感知板，现场演示识别、避障和「不可信时降速复核」整套动作。

源码

一套可复现的仓库

量化脚本、Cube.AI 工程、三档判定、帧间补位、测试数据与复现说明。目标是别人照着能跑出来。

数据

一张实测数据表

精度、帧率、内存、触发率、误动作率，以及满负荷推理下的功耗—温升—帧率包线。

文字

论文与专利

中文期刊或会议论文 1 篇（目标）；发明专利申请 1 项，重点写「触发式定向复核」那条。

两件现在就该说清楚的事

① 发明专利从申请到授权通常要 18–30 个月，九个月内我们最多拿到受理通知书，结题时不会说「专利已经授权」。

② 论文目标是中文期刊或本科生学术会议，不承诺 EI/SCI——按我们的时间和能力，这个预期才是诚实的。

一句话总结交付：不是「一个能识别东西的小车」，是「一套在 4 fps 上还不出事的感知做法，连同它失败的可能」。

耐劳苦 尚俭朴 勤学业 爱国家

重庆大学
CHONGQING UNIVERSITY

05 团队与分工

四个人，四个专业，各自有真正能落地的活
没有人只挂名

耐劳苦，尚俭朴，
勤学业，爱国家。

谁干什么

TEAM · 四个人四块，都对着自己的专业

成员	专业方向	负责模块	交付物
陶家宇（队长）	计算机	系统架构、Cube.AI 部署链路、三档判定模块	全链路打通；论文主笔
李海洋	计算机	模型选型与量化、数据集采集标注、PC 端工具链	量化脚本、数据集、精度报告
徐熠冉	能源动力	电源与功耗、热稳态实测、续航与电池压降	功耗—温升—帧率包线数据
王紫怡	电气	电机驱动、编码器与 IMU 采集、板级硬件与联调	底盘联调、硬件原理说明
刘 寄	指导教师	方向把关、工具链答疑、论文与专利指导	—

进度（与系统内已提交的里程碑一致）

调研选型	量化预演	端侧推理	融合联调	系统优化	结题
11.30	02.19	04.14	06.16	07.15	08.15

分工的原则是：每个人手里都有一份能独立验收、能写进报告的东西。

尤其功耗—温升这一块不是「顺便测一下」——满负荷推理会让 H7 发热降频、18650 掉压复位，这条包线直接决定车能连续跑多久。

耐劳苦 尚俭朴 勤学业 爱国家

参考文献

REFERENCES · 原文已归档在本项目的「参考文献原文」文件夹

[1] Lai L, Suda N, Chandra V. CMSIS-NN: Efficient Neural Network Kernels for Arm Cortex-M CPUs[EB/OL]. arXiv:1801.06601, 2018.

[2] Banbury C, Reddi V J, Torelli P, et al. MLPerf Tiny Benchmark[C]//NeurIPS Datasets and Benchmarks Track, 2021.

[3] Burrello A, Garofalo A, Bruschi N, et al. DORY: Automatic End-to-End Deployment of Real-World DNNs on Low-Cost IoT MCUs[J]. IEEE Trans. on Computers, 2021. doi:10.1109/TC.2021.3066883

[4] Moosmann J, Müller H, Zimmerman N, et al. Flexible and Fully Quantized Lightweight TinyissimoYOLO for Ultra-Low-Power Edge Systems[J]. IEEE Access, 2024. doi:10.1109/ACCESS.2024.3404878

[5] Lin J, Zhu L, Chen W M, et al. Machine Learning for Microcontroller-Class Hardware: A Review[J]. IEEE Sensors Journal, 2022. arXiv:2205.14550

[6] Banbury C, Zhou C, Fedorov I, et al. MicroNets: Neural Network Architectures for Deploying TinyML Applications on Commodity Microcontrollers[C]//MLSys, 2021.

[7] David R, Duke J, Jain A, et al. TensorFlow Lite Micro: Embedded Machine Learning on TinyML Systems[C]//MLSys, 2021.

[8] Jacob B, Kligys S, Chen B, et al. Quantization and Training of Neural Networks for Efficient Integer-Arithmetic-Only Inference[C]//CVPR, 2018: 2704-2713.

[9] Geifman Y, El-Yaniv R. Selective Classification for Deep Neural Networks[C]//NeurIPS, 2017.

[10] Guo C, Pleiss G, Sun Y, et al. On Calibration of Modern Neural Networks[C]//ICML, 2017: 1321-1330.

[11] 马官正. 面向嵌入式设备的轻量级目标检测算法综述[J]. 无线互联科技, 2026(12).

[12] 邓 览. 基于深度学习的轻量化目标检测模型综述[J]. 信息技术与信息化, 2026(6): 170-173.

开源与官方资料：STMicroelectronics/stm32ai-modelzoo · RangiLyu/nanodet · Flora233333/Deploy-SSD-ON-STM32 · ST Wiki「STM32Cube.AI model performances」

耐劳苦 尚俭朴 勤学业 爱国家



重庆大学

CHONGQING UNIVERSITY

敬请各位专家批评指正

答辩人：陶家宇，王紫怡，李海洋，徐熠冉

指导老师：刘 寄